

RAPPORT DE PROJET

Détection Anti-Spoofing de Visage par ACP

réalisé par : Derriche Rania

Introduction

Ce projet porte sur la detection automatique de visages falsifies, c'est-à-dire distinguer un vrai visage (une personne réelle devant une camera) d'un faux visage (une photo imprimee, une video rejouee sur ecran, ou un masque). Ce probleme s'appelle le Face Anti-Spoofing et il est tres important pour la securite des systemes de reconnaissance faciale qu'on retrouve partout aujourd'hui : deverrouillage de telephone, controle d'accès, paiement biometrique.

Le projet est divise en deux parties complementaires, chacune apportant une approche differente pour resoudre le meme probleme :

- Partie 1 : utilisation d'un reseau de neurones profond (EfficientNet-B4) comme extracteur de features, suivie d'une ACP et de classifieurs classiques (SVM, KNN, Regression Logistique). Le dataset est telecharge depuis Roboflow.
- Partie 2 : approche directe sur les pixels bruts des images (64x64), avec ACP appliquee directement sur les pixels et cinq classifieurs compares (SVM, Random Forest, Regression Logistique, Gradient Boosting, MLP). Le dataset utilise est LCC_FASD.

Partie 1 : Pipeline EfficientNet-B4 + ACP + Classifieurs (Redjah Yousra Sarah)

Dataset utilise

Le dataset utilise dans cette partie est le Face Anti-Spoofing dataset disponible sur la plateforme Roboflow. Il contient des images de visages reels et de visages falsifies, decoupees en trois ensembles : entraînement (train), validation (valid) et test. Les images sont annotees au format YOLOv8, ou chaque fichier texte indique si l'image correspond a un visage reel (classe 0) ou falsifie (classe 1).

Etapas du pipeline

Le pipeline complet suit cinq etapes sequentielles :

Etape 1 : Exploration des donnees (EDA)

On commence par compter le nombre d'images par classe et par split (train/valid/test) et on visualise la distribution avec des graphiques. On affiche aussi des exemples d'images réelles et falsifiées pour mieux comprendre les différences visuelles entre les deux classes.

Etape 2 : Extraction de features avec EfficientNet-B4

Plutot que de travailler directement sur les pixels bruts, on utilise EfficientNet-B4, un reseau de neurones profond pre-entraîne sur ImageNet (1.2 million d'images). On enleve sa derniere couche de classification et on garde uniquement le reste du reseau comme extracteur : chaque image est ainsi representee par un vecteur de 1792 valeurs qui encode des informations profondes sur la texture, les contours et les patterns visuels, des éléments très utiles pour detecter le spoofing.

Les images sont d'abord redimensionnees a 224x224 pixels et normalisees selon les statistiques ImageNet avant d'être passees dans le reseau.

Etape 3 : ACP (Analyse en Composantes Principales)

Les 1792 features extraites sont ensuite reduites par l'ACP. Avant d'appliquer l'ACP, on normalise les donnees avec un StandardScaler (chaque feature est centree et mise a l'echelle). On choisit le nombre de composantes qui permet de capturer 95% de la variance totale. L'ACP permet de decorreler les features et de reduire la dimensionnalite, ce qui aide les classifieurs à apprendre plus facilement.

Des visualisations sont generees : courbe de variance cumulee, projections 2D et 3D dans l'espace ACP, pour verifier que les classes sont bien separables.

Details de ACP :

Matrice de Corrélation R :




Figure 1 matrice de Corrélation R

La matrice de corrélation des features originales (avant ACP) révèle une redondance significative entre les 1792 features extraites par EfficientNet-B4, avec une corrélation moyenne de $|r| = 0.098$, traduisant de nombreuses dépendances linéaires entre les descripteurs. Après application de l'ACP, la matrice des composantes principales affiche une corrélation moyenne de $|r| = 0.000$, confirmant leur orthogonalité parfaite : chaque axe factoriel capture une direction de variance strictement indépendante des autres, ce qui élimine toute redondance et garantit que l'information apportée par chaque composante est unique et non redondante.

Interprétation des Valeurs Propres (λ)

PC1 est l'axe dominant avec $\lambda = 139.73$, soit presque le double de PC2 ($\lambda = 76.70$). Cela signifie que la première direction de variance dans l'espace EfficientNet-B4 est nettement plus informatrice que toutes les autres — il existe une structure principale forte dans les données, probablement liée à la distinction globale texture naturelle vs texture artificielle.

La décroissance est rapide entre PC1 et PC5 (de 139.73 à 45.95), puis elle ralentit progressivement jusqu'à PC10 (31.77). Il n'y a pas de "coude" brutal, ce qui est typique des features CNN : l'information est distribuée progressivement, sans qu'un seul axe ne résume tout.

Un chiffre important : il faut **10 composantes pour atteindre seulement 31.63% de variance cumulée**. Cela confirme que les 1792 features EfficientNet sont très riches et multidimensionnelles — aucun petit sous-ensemble d'axes ne suffit, d'où le choix de **300 composantes pour couvrir 92.82% de la variance totale**.

Ce choix de 300 CP est justifié par la courbe de variance cumulée : en dessous de ce seuil, une partie significative de l'information discriminante serait perdue, ce qui dégraderait les performances du classifieur. Au-delà, on commencerait à incorporer du bruit, comme le confirme l'analyse de sensibilité qui montre une baisse de précision au-delà de 150-200 composantes.

Tableau Valeur propre

Tableau des 10 premières valeurs propres :			
CP	λ (valeur propre)	Variance (%)	Cumulée (%)
PC1	139.7276	7.79	7.79
PC2	76.7006	4.28	12.07
PC3	62.2912	3.47	15.55
PC4	54.3489	3.03	18.58
PC5	45.9496	2.56	21.14
PC6	42.7312	2.38	23.53
PC7	40.4726	2.26	25.78
PC8	37.4656	2.09	27.87
PC9	35.4996	1.98	29.85
PC10	31.7680	1.77	31.63

NOTE :

La visualisation dans le plan factoriel ($PC1 \times PC2$) constitue une projection en deux dimensions d'un espace initialement réduit à 300 composantes principales, lui-même issu d'un vecteur de 1792 features extrait par EfficientNet-B4. Bien que la classification repose sur l'intégralité des 300 composantes retenues — couvrant 92.82% de la variance totale — il est impossible de représenter graphiquement un espace de si haute dimension. PC1 et PC2 sont les axes les plus pertinents à étudier visuellement car ils concentrent la part la plus élevée de variance expliquée, respectivement 7.8% et 4.3%, et constituent ainsi la projection 2D qui préserve au mieux la structure globale des données. Cette représentation permet d'interpréter les relations entre variables et individus sans prétendre résumer l'intégralité de l'information, mais en offrant la fenêtre la plus informative que l'œil humain puisse appréhender




Figure 2 : cercle de corrélation

Axe PC1 (7.8% de variance — axe horizontal)

PC1 est l'axe qui capture la plus grande part de variance du dataset dans ce plan. La lecture des corrélations avec cet axe se fait sur la projection horizontale de chaque flèche.

Features fortement et positivement corrélées à PC1 (flèches pointant franchement vers la droite) :

F713 et F1140 sont les mieux représentées dans le plan (couleur la plus verte, $\cos^2$ élevé) et sont quasiment alignées sur l'axe PC1 horizontal — leur corrélation avec PC1 est maximale et leur

composante sur PC2 est quasi nulle. Ce sont les features les plus "pures" de PC1. F983, F580, F1581 suivent avec des flèches longues et bien orientées vers la droite, légèrement inclinées vers PC2. F325, F745, F1587, F334, F397, F814, F1639, F1319, F393 ont des projections positives significatives sur PC1 mais des longueurs légèrement plus courtes, indiquant une corrélation modérée à forte avec cet axe.

Interprétation de PC1 : toutes ces features augmentent simultanément dans la même direction. PC1 représente donc un **facteur commun fort** entre ces 18 features — un profil visuel partagé que EfficientNet-B4 a détecté de façon cohérente dans le dataset. Les images qui ont un score élevé sur PC1 sont celles qui activent fortement toutes ces features ensemble.

Features négativement corrélées à PC1 :

F1564 et F1288 pointent vers la gauche (PC1 négatif) avec une longueur d'environ 0.5 unité, mais leur couleur **jaune** indique un $\cos^2$ faible — elles sont **mal représentées dans ce plan (PC1, PC2)**. Leur corrélation négative avec PC1 est réelle mais ne s'exprime pas principalement dans ce plan ; l'essentiel de leur information se trouve dans des axes de rang supérieur (PC3, PC4...). On ne peut donc pas tirer de conclusion forte sur leur rôle à partir de ce seul plan.

Axe PC2 (4.3% de variance — axe vertical)

PC2 est orthogonal à PC1 et capture une information complémentaire et indépendante. La lecture se fait sur la projection verticale de chaque flèche.

Features positivement corrélées à PC2 (composante verticale vers le haut) :

F936 est la feature la plus corrélée à PC2 parmi toutes — sa flèche est la plus inclinée vers le haut, avec une projection verticale nettement supérieure aux autres (environ +0.42 sur l'axe PC2). Elle est aussi bien corrélée à PC1 (projection horizontale positive d'environ +0.65). F936 est donc la seule feature véritablement **bi-corrélée** aux deux axes simultanément, ce qui en fait la variable la plus informative du plan dans son ensemble.

F393, F1319, F1639 et F814 ont des composantes positives sur PC2 mais plus modestes (entre +0.1 et +0.3), et sont davantage alignées sur PC1. Leur contribution à PC2 est secondaire par rapport à leur contribution à PC1.

Features négativement corrélées à PC2 (composante verticale vers le bas) :

F1581 et F580 ont des projections verticales négatives nettes (environ -0.2 à -0.25 sur PC2) tout en restant bien corrélées à PC1 positivement. Cela signifie qu'elles évoluent **en sens inverse de F936 sur PC2** : quand F936 est élevée pour une image, F1581 et F580 tendent à être plus faibles, et inversement. Ces deux paires de features encodent donc deux profils opposés sur la dimension PC2.

F1564 et F1288 ont aussi une composante négative sur PC2 (environ -0.45), mais leur faible $\cos^2$ (couleur jaune) rend cette observation peu fiable dans ce plan.

Features non corrélées à PC2 (projection verticale nulle) :

F713, F1140, F983, F745, F325, F1587, F334, F397 ont leurs flèches quasiment alignées sur l'axe horizontal, avec une composante verticale proche de zéro. Leur corrélation avec PC2 est **négligeable** — elles n'apportent aucune information sur ce que PC2 mesure. Toute leur information dans ce plan est portée exclusivement par PC1.

Conclusion des deux axes

PC1 structure le plan de façon **globale et dominante** : 18 features sur 20 y contribuent positivement, ce qui signifie qu'il existe un gradient fort et cohérent dans les données, probablement lié à la distinction principale entre visages réels et falsifiés. PC2, plus fin, **affine cette structure** en séparant deux sous-profils à l'intérieur des données : les images qui activent fortement F936 (quadrant haut-

droit) s'opposent à celles qui activent davantage F1581 et F580 (quadrant bas-droit), même si toutes partagent des valeurs positives sur PC1. Ce deuxième axe capture donc vraisemblablement une **variation intra-classe** — par exemple différents types d'attaques Fake, ou différentes conditions de capture pour les images Real.




Figure 3 , visualisation / projection des individu sur les deux axe + les variables

Lecture globale avant les axes

La première observation frappante est la **séparation spatiale nette** entre les deux classes sur ce plan. Les points **Real (vert)** occupent massivement la **partie gauche** du graphique (PC1 négatif, de -15 à 0 environ), avec une très grande dispersion verticale sur PC2 (de -25 à +15). Les points **Fake (rose)** se scindent en deux groupes : une partie mélangée avec les Real sur la gauche, et surtout un **cluster compact et isolé sur la droite** (PC1 entre +15 et +25, PC2 proche de 0).

Les **12 flèches-variables** pointent toutes vers la droite — exactement dans la direction du cluster Fake compact. Ce n'est pas une coïncidence : c'est le lien direct entre variables et individus que permet le biplot.

Interprétation selon PC1 (axe horizontal — 7.8% de variance)

Du côté des variables : toutes les flèches ont une composante positive forte sur PC1 — F713, F1140, F983, F745, F334, F1587, F393, F1319, F936, F1581, F580 pointent toutes vers la droite. Cela signifie que des **valeurs élevées de toutes ces features correspondent à des scores positifs sur PC1**.

Du côté des individus : les images Real se concentrent sur les scores **négatifs** de PC1 (gauche), et le cluster Fake compact se concentre sur les scores **très positifs** de PC1 (droite, entre +15 et +25).

Lecture combinée : le biplot révèle que les features F713, F1140, F983, F745, F1587, F334, F1581, F580, F936, F393, F1319 sont toutes des **descripteurs caractéristiques des images Fake**. Les images qui activent fortement ces features dans EfficientNet-B4 se retrouvent dans le cluster Fake à droite. À l'inverse, les images Real ont des **valeurs faibles voire négatives** sur ces mêmes features — elles ne déclenchent pas ces détecteurs, ce qui se traduit par des scores négatifs sur PC1 et une position à gauche du plan.

PC1 est donc bien **l'axe de discrimination principal Real/Fake** dans ce dataset : il oppose deux régimes de features, l'un associé aux artefacts visuels des faux visages (droite), l'autre à l'absence de ces artefacts pour les vrais visages (gauche).

Interprétation selon PC2 (axe vertical — 4.3% de variance)

Du côté des variables : on observe une dispersion verticale claire des flèches sur PC2. F936 pointe fortement vers le **haut** (PC2 positif $\approx +9$), F393 et F1319 pointent modérément vers le haut. En revanche, F1581 et F580 pointent vers le **bas** (PC2 négatif ≈ -3). Les autres — F713, F1140, F983, F745, F334, F1587 — sont quasiment alignées sur l'axe horizontal, donc peu corrélées à PC2.

Du côté des individus : les points Real sont dispersés sur toute la hauteur du plan (PC2 de -25 à $+15$), sans structure verticale claire — PC2 ne discrimine pas les Real entre eux de façon organisée. Le cluster Fake compact à droite, lui, est centré autour de PC2 ≈ 0 , ce qui signifie que ces images activent uniformément F713, F1140, F983 (neutres sur PC2) mais pas particulièrement F936 ni F1581. On note quelques points Fake dispersés sur la gauche, certains avec des PC2 positifs (autour de $+8$ à $+10$), qui correspondent vraisemblablement à des types d'attaques différents activant davantage F936.

Lecture combinée : PC2 ne sépare pas Real de Fake mais **affine la structure interne des Fake**. Les images Fake qui ont des scores positifs sur PC2 (en haut à gauche du nuage mélangé) activent fortement F936 — ce sont probablement des attaques d'un type particulier (par exemple masque 3D ou deepfake avec une luminosité spécifique). Les images Fake avec des scores négatifs sur PC2 activent davantage F1581 et F580 — un autre type d'attaque (photo imprimée, attaque 2D). Les Real, eux, sont dispersés verticalement car leurs variations sur PC2 reflètent simplement la diversité naturelle des conditions de capture (éclairage, angle, fond), non liée au spoofing.

Synthèse double — Ce que le biplot dit en un seul message

Le biplot confirme que les 12 features sélectionnées sont toutes des **détecteurs d'artefacts de spoofing**. Elles tirent toutes les images vers la droite de PC1 proportionnellement à leur intensité — les images qui les activent fortement sont Fake, celles qui ne les activent pas sont Real. PC2 introduit une nuance supplémentaire : parmi les Fake, F936 distingue un sous-type d'attaque (haut) de celui détecté par F1581/F580 (bas), révélant que le dataset contient des **attaques hétérogènes** que le modèle traite différemment dans l'espace factoriel, même si tous finissent correctement classifiés comme Fake grâce aux 300 composantes exploitées par le classifieur.

Etape 4 : Classification et évaluation

Trois classifieurs sont entraînés sur les composantes principales : SVM avec noyau RBF, KNN ($k=7$) et Regression Logistique. Chaque modèle est évalué sur le jeu de test avec plusieurs métriques : accuracy, precision, rappel, F1-score et AUC-ROC. Une validation croisée à 5 folds est aussi réalisée pour estimer la stabilité des résultats.

Resultats

Les résultats obtenus sur le dataset Face Anti-Spoofing de Roboflow confirment l'efficacité du pipeline basé sur l'extraction de features profondes (EfficientNet-B4) combinée à une réduction de dimensionnalité par ACP.


3.1 Tableau comparatif des performances

Classifieur	Test Accuracy	CV-5 Accuracy	AUC-ROC
SVM (noyau RBF)	94.85%	99.80%	0.993
KNN (k=7)	95.88%	95.78%	0.978
Regression Logistique	91.75%	99.47%	0.971

Tableau 1 : Comparaison des classifieurs sur le jeu de test et en validation croisee 5-folds

3.2 Analyse des courbes ROC

Les courbes ROC obtenues confirment les excellentes performances des trois classifieurs, tres au-dessus de la ligne de reference aleatoire (AUC = 0.500). La figure ci-dessous presente la comparaison des courbes ROC pour les trois modeles.



[Figure 1 : Courbes ROC Comparaison des Classifieurs]

3.3 Analyse par classifieur

SVM avec noyau RBF

Le SVM (RBF) est le meilleur classifieur sur ce type de features profondes, avec une AUC-ROC de 0.993 et une accuracy en validation croisee de 99.80%. Sa capacite a definir des hyperplans non lineaires dans l'espace reduit par l'ACP lui permet de separer efficacement les visages reels des visages falsifies.

- Test Accuracy : 94.85%
- CV-5 Accuracy : 99.80% (meilleure stabilite)
- AUC-ROC : 0.993 (quasi-parfait)

KNN (k=7)

Le KNN beneficie directement de la reduction de dimensionnalite par l'ACP : dans un espace de faible dimension (300 composantes au lieu de 1792), les distances euclidiennes deviennent plus significatives


et représentatives. Il obtient la meilleure accuracy sur le jeu de test (95.88%) mais une stabilité CV légèrement inférieure au SVM.

- Test Accuracy : 95.88% (meilleure accuracy test)
- CV-5 Accuracy : 95.78%
- AUC-ROC : 0.978

Regression Logistique

La regression logistique donne des performances légèrement inférieures car elle est limitée à une séparation linéaire dans l'espace des composantes principales. Cependant, sa CV-5 accuracy de 99.47% montre qu'elle reste très compétitive et stable, constituant une excellente référence de base.

- Test Accuracy : 91.75%
- CV-5 Accuracy : 99.47%
- AUC-ROC : 0.971



[Figure 2 : Matrice de Confusion — Comparaison des Classifieurs]

SVM (RBF) — Accuracy : 94.85%

- 32 vrais positifs (Real bien classés) → très bon rappel sur les visages réels
- 60 vrais négatifs (Fake bien classés) → excellente détection du spoofing
- 1 faux négatif : 1 visage réel classé comme fake → erreur peu grave (pas de faux rejet d'un utilisateur légitime catastrophique)
- 4 faux positifs : 4 visages falsifiés classés comme réels → c'est l'erreur la plus critique en anti-spoofing car elle laisse passer des attaques

Précision Real = $32/36 = 88.9\%$ | Rappel Real = $32/33 = 97.0\%$ Précision Fake = $60/61 = 98.4\%$ | Rappel Fake = $60/64 = 93.8\%$

KNN (k=7) : Accuracy : 95.88% (meilleure)

- 63 vrais négatifs → meilleure détection des faux visages parmi les 3 modèles
- Seulement 1 faux positif → quasiment aucune attaque ne passe, c'est excellent pour la sécurité
- 3 faux négatifs : 3 vrais visages classés comme fake → légère hausse des faux rejets

Précision Real = $30/31 = 96.8\%$ | Rappel Real = $30/33 = 90.9\%$ Précision Fake = $63/66 = 95.5\%$ | Rappel Fake = $63/64 = 98.4\%$

Le KNN est le plus sûr du point de vue sécurité : il laisse passer le moins d'attaques (1 seul Fake mal classé).

Régression Logistique : Accuracy : 91.75% (*plus faible*)

- 6 faux positifs : 6 visages falsifiés passent inaperçus → c'est le moins bon résultat sur l'erreur critique
- 2 faux négatifs : 2 vrais visages rejetés à tort

Précision Real = $31/37 = 83.8\%$ | Rappel Real = $31/33 = 93.9\%$ Précision Fake = $58/60 = 96.7\%$ | Rappel Fake = $58/64 = 90.6\%$

La limite linéaire de ce modèle explique ses difficultés à séparer parfaitement les deux classes dans l'espace ACP.

PETIT TESTE RAPIDE sur de la data et verification avec lable etiqueté:



EN CONCLUSION :

Les resultats exacts dependent de la taille du dataset Roboflow et des parametres d'ACP trouves. Le SVM avec noyau RBF est generalement le meilleur classifieur sur ce type de features profondes, suivi du KNN qui beneficie directement de la reduction de dimensionnalite par l'ACP (les distances euclidiennes deviennent plus significatives dans un espace de faible dimension). La Regression Logistique donne des performances un peu plus basses car elle est limitee a une separation lineaire.

Le pipeline montre qu'il est possible d'obtenir de bonnes performances sans entrainer un reseau de neurones de bout en bout, ce qui est un avantage important dans un contexte academique avec des ressources GPU limitees.

Partie 2 : Pipeline ACP directe sur pixels + 5 classifieurs (Derriche Rania)

Dataset utilise

Cette partie utilise le dataset LCC_FASD (Local Color Contrast Face Anti-Spoofing Dataset). Il contient des images de visages réels et falsifiées organisées dans deux dossiers : un dossier 'real' et un dossier 'spooft'. Au total, 2254 images réelles et 7046 images de spoofing sont disponibles. Pour avoir un dataset équilibré, on sélectionne aléatoirement 2254 images de spoofing, ce qui donne un total de 4508 images avec une distribution parfaite 50/50 entre les deux classes.

Etapes du pipeline

Etape 1 : Chargement et exploration

Les images sont chargées depuis les deux dossiers, converties en niveaux de gris et redimensionnées à 64x64 pixels. Cela donne un vecteur de 4096 valeurs par image (64 x 64). On sélectionne aléatoirement des images de spoofing pour équilibrer les classes, puis on visualise des exemples des deux classes.

Categorie	Nombre d'images	Pourcentage
Reel	2 254	50%
Fake (selectionne)	2 254	50%
Total	4 508	100%

Etape 2 : Preprocessing


Les pixels des images sont normalisés : les valeurs passent de [0, 255] à [0, 1]. Le dataset est ensuite divisé en 80% pour l'entraînement (3606 images) et 20% pour le test (902 images).

Etape 3 : ACP sur les pixels bruts


L'ACP est appliquée directement sur les vecteurs de pixels (4096 dimensions). On réduit à 50 composantes principales, ce qui permet de capturer 88.2% de la variance totale. Avant l'ACP, un StandardScaler est appliqué.

Les visualisations générées sont :

- Matrice De Corrélation :




- Courbe de variance cumulée : 21 composantes suffisent pour atteindre 80% de variance




- Eigenvectors :

Vecteurs propres (Eigenvectors) — 6 premiers axes de l'ACP
Chaque image représente UNE direction dans l'espace pixel
Rouge = activation positive | Bleu = activation négative




- Eigenfaces : les 15 premières composantes affichées comme images, elles montrent les directions de variation les plus importantes dans les visages

Eigenfaces — 15 premières composantes principales de l'ACP
(Rouge = forte activation positive | Bleu = forte activation négative)



- Projection 2D (PC1 vs PC2) et 3D : pour visualiser la séparabilité des deux classes dans l'espace réduit

Représentation des données dans les axes principaux (ACP)
Réel (bleu) vs Fake (rouge)



- Reconstruction : démonstration de la qualité de reconstruction avec différents nombres de composantes



Etape 4 : Entraînement des 5 classifieurs

Cinq classifieurs différents sont entraînés sur les composantes ACP et comparés :

Classifieur	Accuracy Train	Observations
SVM (RBF)	97.9%	Bon équilibre
Random Forest	100%	Surapprentissage probable
Regression Logistique	72.5%	Modèle simple
Gradient Boosting	99.4%	Tres performant
MLP (Reseau de neurones)	98.7%	Bon apprentissage


Etape 5 : Evaluation sur le jeu de test

Les 5 modèles sont évalués sur les 902 images de test (451 réelles et 451 fake). Les métriques utilisées sont : accuracy, precision, recall, F1-score et AUC-ROC.

Resultats

Voici les résultats obtenus sur le jeu de test, classés par accuracy décroissante :

Classifieur	Accuracy	F1-score	AUC-ROC	Rang
SVM (RBF)	92.68%	0.93	0.974	1er Meilleur
MLP (Reseau de neurones)	91.80%	0.92	0.964	2eme
Gradient Boosting	89.58%	0.90	0.958	3eme
Random Forest	88.91%	0.89	0.955	4eme
Regression Logistique	72.06%	0.72	0.808	5eme



Le SVM avec noyau RBF est le meilleur classifieur avec une accuracy de 92.68% et une AUC-ROC de 0.974. Cela signifie qu'il classe correctement plus de 9 images sur 10, et qu'il est très bon pour distinguer les vrais visages des faux. Le MLP arrive juste derrière avec 91.80%, montrant que les réseaux de neurones sont aussi très efficaces sur ce problème.

Le Random Forest atteint 100% d'accuracy sur l'entraînement mais seulement 88.91% sur le test, ce qui montre qu'il a un peu surappris les données d'entraînement. La Regression Logistique donne les résultats les plus faibles (72.06%), ce qui est attendu pour un modèle linéaire appliqué à un problème avec des données de haute dimensionnalité.

Test du meilleur modèle (SVM RBF)

Pour vérifier que le modèle fonctionne vraiment, on a testé le SVM avec noyau RBF (le meilleur classifieur avec 92.68% d'accuracy) sur trois types d'images différentes : un vrai visage humain, un visage généré par IA (spoof), et une photo de chien. L'objectif est de voir si le modèle arrive bien à faire la différence entre un vrai visage et le reste.

Test 1 : Vrai visage humain

On a donné au modèle une photo d'un vrai visage humain prise directement. Le résultat est correct : le modèle a détecté un visage RÉEL avec une confiance de 99.3%. Cela montre que le modèle reconnaît bien les caractéristiques d'un vrai visage dans l'espace ACP.




Figure : Test avec un vrai visage humain → RÉEL (confiance 99.3%)

Test 2 : Visage généré par intelligence artificielle (spoof)

Pour le test de détection d'un faux visage, on a utilisé une image générée par IA (site thispersondoesnotexist.com). Le modèle a bien classé cette image comme SPOOF avec une confiance de 96.5%. Ce résultat est très satisfaisant car ce type de visage synthétique est précisément ce qu'on cherche à détecter dans un système anti-spoofing.




Figure : Test avec un visage généré par IA → SPOOF (confiance 96.5%)

Test 3 : Image hors distribution (photo d'un chien)

Pour tester les limites du modèle, on a utilisé une photo de chien, c'est-à-dire une image complètement hors de la distribution du dataset. Le modèle a répondu SPOOF avec 99.7% de confiance. Ce résultat est attendu et logique : le modèle est entraîné uniquement sur des visages humains, donc toute image qui ne ressemble pas à un vrai visage sera automatiquement classée comme fausse. Il ne peut pas répondre "je ne sais pas", il est obligé de choisir entre les deux classes.




Figure : Test avec une photo de chien (hors distribution) → SPOOF (confiance 99.7%)

Résumé des tests

Image testée	Résultat attendu	Résultat obtenu	Confiance
Vrai visage humain	RÉEL	✓ RÉEL	99.3%
Visage généré par IA	SPOOF	✗ SPOOF	96.5%
Photo d'un chien (hors distribution)	Non défini	SPOOF (attendu)	99.7%

Conclusion

Ce projet montre deux approches différentes pour résoudre le même problème de détection anti-spoofing. La première partie utilise un réseau de neurones profond pre-entraîné pour extraire des features riches avant d'appliquer l'ACP, ce qui permet d'obtenir de bonnes représentations sans avoir besoin de beaucoup de données ni de GPU puissant. La deuxième partie applique l'ACP directement sur les pixels bruts des images, une approche plus classique mais qui fonctionne bien grâce au bon choix de classifieurs.

Dans les deux cas, le SVM avec noyau RBF se distingue comme le meilleur classifieur, ce qui confirme son efficacité sur des problèmes de classification binaire avec des features de moyenne dimensionnalité. L'ACP joue un rôle clé dans les deux approches : elle réduit le bruit, décolle les features et accélère l'apprentissage des classifieurs.